PROYECTO PRIMER PARCIAL DE INTELIGENCIA ARTIFICIAL

I PORTADA

Tema:	Sistema de Soporte a la Toma de Decisiones Médicas: Clasificación de Riesgo en Salud Materna mediante Lógica Difusa y Algoritmos Genéticos
Carrera:	Ingeniería de Software
Unidad de Organización Curricular:	PROFESIONAL
Nivel y Paralelo:	Séptimo semestre
Alumnos participantes:	Bonilla Joel Garcia Josue
Asignatura:	Inteligencia Artificial
Docente:	

II INFORME DEL PROYECTO

2.1. Introducción y Objetivos

2.1.1. Contexto

La mortalidad materna representa uno de los indicadores de salud pública más críticos a nivel mundial. Según la Organización Mundial de la Salud, aproximadamente 287.000 mujeres mueren cada año por complicaciones relacionadas con el embarazo o el parto, siendo la gran mayoría de estas muertes prevenibles con una detección y atención oportuna del riesgo [1]. En países en vías de desarrollo, la escasez de personal médico especializado y el acceso limitado a centros de salud agravan esta problemática, haciendo necesario el desarrollo de herramientas de apoyo clínico que puedan asistir a médicos generales y personal de enfermería en la identificación temprana de pacientes en situación de riesgo.

Ante esta necesidad surge la propuesta de un **Sistema de Soporte a la Toma de Decisiones Médicas** centrado en la clasificación del nivel de riesgo durante el embarazo. El sistema analiza seis parámetros clínicos básicos —edad, presión arterial sistólica, presión arterial diastólica, azúcar en sangre, temperatura corporal y frecuencia cardíaca— y determina si la paciente se encuentra en una categoría de *bajo riesgo*, *riesgo medio* o *alto riesgo*.

2.1.2. Por qué Lógica Difusa

La lógica difusa [2] permite codificar el conocimiento médico experto en la forma de reglas lingüísticas comprensibles y auditables, por ejemplo: *"SI la presión es alta Y la edad es avanzada, ENTONCES el riesgo es alto"*. Un médico puede leer, verificar y cuestionar cada regla del sistema. Esta **interpretabilidad** es fundamental en entornos clínicos donde las decisiones tienen consecuencias directas sobre la vida de las pacientes.

Adicionalmente, la lógica difusa maneja de forma natural la incertidumbre inherente a las mediciones médicas y la transición gradual entre estados clínicos (por ejemplo, la frontera entre presión "normal" y presión "elevada" no es una línea abrupta).

2.1.3. Por qué un Algoritmo Genético

Los parámetros de las funciones de membresía deben ajustarse al dataset específico de riesgo materno. Este es un problema de optimización en espacio continuo de alta dimensión con función objetivo no diferenciable, para el cual los algoritmos genéticos [3] son la herramienta adecuada. La justificación técnica detallada se presenta en la Sección 2.5.1.

2.1.4. Objetivo General

Desarrollar un sistema web de soporte a la toma de decisiones clínicas que, a partir de seis variables vitales básicas de una paciente embarazada, clasifique automáticamente su nivel de riesgo materno en tres categorías (bajo, medio, alto) utilizando un motor de inferencia basado en lógica difusa Mamdani, cuyas funciones de membresía han sido optimizadas mediante un algoritmo genético.

2.1.5. Objetivos Específicos

- Definir las variables lingüísticas y las funciones de membresía trapezoidales del sistema difuso con base en literatura médica especializada.
- Diseñar un conjunto de reglas difusas clínicamente justificadas para la clasificación de riesgo materno.
- Implementar el motor de inferencia Mamdani con fuzzificación, evaluación de reglas y defuzzificación por centroide.
- Optimizar las funciones de membresía mediante un algoritmo genético multiobjetivo que equilibre precisión, sensibilidad al alto riesgo e interpretabilidad.
- Exponer el sistema como una API REST (FastAPI) integrada con una interfaz web (React) que permita la consulta interactiva y la visualización de las curvas de membresía.

2.2. Dataset y Selección

2.2.1. Fuente y Descripción del Dataset

El dataset utilizado es el **Maternal Health Risk Data Set**, disponible en el repositorio UCI Machine Learning Repository [4]. Fue recolectado de hospitales, clínicas y centros de atención primaria rurales de Bangladesh mediante un sistema de monitoreo del Internet de las Cosas (IoT).

El dataset contiene **1.014 registros** de pacientes embarazadas, cada uno descrito por seis variables numéricas continuas y etiquetado con un nivel de riesgo asignado por criterio clínico experto.

Variable (CSV)	Nombre interno	Unidad	Rango
Age	edad	años	10 – 70
SystolicBP	presion_sistolica	mmHg	70 – 160
DiastolicBP	presion_diastolica	mmHg	49 – 100
BS	azucar_sangre	mmol/L	6 – 19
BodyTemp	temperatura_corporal	°F	97 – 103
HeartRate	frecuencia_cardiaca	lpm	60 – 90

Fuente: Elaboración propia.

La variable objetivo `RiskLevel` toma tres valores: *low risk*, *mid risk* y *high risk*.

Clase	Registros	Porcentaje
low risk	406	40.0 %
mid risk	336	33.1 %
high risk	272	26.8 %
Total	**1.014**	**100 %**

Fuente: Elaboración propia.

2.2.2. Justificación de la Elección del Dataset

La elección de este dataset sobre otras alternativas estuvo motivada por tres razones principales:

1. **Variables continuas fuzzificables:** Todas las variables de entrada son valores numéricos continuos dentro de rangos bien definidos. Esto es ideal para la lógica difusa, que requiere definir curvas de membresía sobre un universo continuo. Un dataset con variables categóricas o binarias no se presta naturalmente a este enfoque.

2. **Dominio médico con conocimiento experto disponible:** Existe abundante literatura clínica sobre los rangos normales y patológicos de cada una de las seis variables, lo que permitió definir las categorías lingüísticas y sus parámetros de forma informácion por evidencia científica y no de manera arbitraria.

3. **Tamaño adecuado para validación:** Con 1.014 registros es posible realizar una partición estratificada entrenamiento/validación/prueba que permita evaluar el desempeño del sistema y del proceso de optimización de manera confiable.

2.2.3. Preprocesamiento

Se identificaron y eliminaron 2 registros con valores de frecuencia cardíaca igual a 7 lpm, claramente inconsistentes con cualquier medición vital posible en una persona viva. El dataset resultante de 1.012 registros fue dividido en tres subconjuntos usando partición **estratificada** (preservando la distribución de clases en cada subconjunto):

Subconjunto	Proporción	Registros aprox.
Entrenamiento	70 %	708
Validación	15 %	152
Prueba	15 %	152

Fuente: Elaboración propia.

El subconjunto de validación se usa durante la optimización genética para evaluar el fitness de cada individuo. El subconjunto de prueba se reserva exclusivamente para la evaluación final del sistema optimizado, garantizando que los resultados reportados no estén sesgados por el proceso de optimización.

2.3. Revisión de Literatura y Definición de Variables Difusas

2.3.1. Proceso de Investigación

La definición de las categorías lingüísticas y de los rangos de las funciones de membresía no fue arbitraria. Se realizó una búsqueda sistemática en las siguientes fuentes de literatura científica:

- PubMed / NCBI (`pubmed.ncbi.nlm.nih.gov`)
- Directory of Open Access Journals — DOAJ (`doaj.org`)
- BASE — Bielefeld Academic Search Engine (`base-search.net`)
- Semantic Scholar (`semanticscholar.org`)
- OpenAlex (`openalex.org`)
- SSRN (`ssrn.com`)
- The Lens (`lens.org`)
- Google Scholar (`scholar.google.com`)
- SciELO (`scielo.org`)
- Elsevier / ScienceDirect (`elsevier.com`)

La búsqueda cubrió más de 205 fuentes y se orientó a responder dos preguntas concretas: (1) *¿Cuáles son los rangos clínicamente aceptados como normales, elevados y patológicos para cada una de las seis variables en mujeres embarazadas?* y (2) *¿Qué combinaciones de variables constituyen indicadores de riesgo en obstetricia según la evidencia publicada?*

Esta búsqueda permitió definir tanto las categorías lingüísticas (por ejemplo, determinar que la presión diastólica se puede clasificar en "normal", "elevada" y "alta") como los puntos de inicio y fin de cada trapezoide a partir de los umbrales clínicos reportados en la literatura. Las reglas del sistema fueron posteriormente diseñadas tomando como base el conocimiento extraído y refinadas iterativamente para resolver los problemas de clasificación detectados durante las pruebas. El Cuadro 1 resume los universos y umbrales clínicos adoptados para cada variable, cuya justificación detallada se presenta en la Sección 2.4.3.

Figura 1: Evidencia de la búsqueda bibliográfica sistemática (más de 205 fuentes consultadas)

Fuente: Elaboración propia.

2.3.2. Trabajos Relacionados

Apriceno et al. (2025) — *A Trustworthy Evolutionary Fuzzy Neural Network Framework for Maternal Health Risk Classification* [5]. Trabajo publicado en AIME 2025 que propone una red neuronal difusa evolutiva que combina un algoritmo genético con un sistema difuso para el mismo dataset Maternal Health Risk de UCI. Sus resultados en términos de precisión y transparencia son comparables al enfoque de este proyecto, validando la aplicabilidad de los métodos evolutivos para este tipo de clasificación médica.

An Explainable Fuzzy Framework for Assessing Preeclampsia Classification (SK-MOEFS) [6]. Propone un marco difuso explicable basado en optimización evolutiva multiobjetivo para clasificar el riesgo de preeclampsia, condición directamente relacionada con la hipertensión durante el embarazo. Alcanza 91 % de exactitud con AUC de 0.89, y genera reglas interpretables en lenguaje natural. Este trabajo demuestra la viabilidad de combinar optimización evolutiva con lógica difusa en el dominio obstétrico con alta interpretabilidad.

Fuzzy Logic Intelligent Systems and Methods in Midwifery and Obstetrics — PMC [7]. Revisión sistemática de la aplicación de lógica difusa en obstetricia y partería. Documenta casos de uso exitosos en diagnóstico, evaluación de riesgo y soporte a decisiones clínicas, y argumenta que la naturaleza gradual de los síntomas clínicos durante el embarazo hace de la lógica difusa una herramienta especialmente adecuada para este dominio.

Enhanced Neuro-Fuzzy System Based on Genetic Algorithm for Medical Diagnosis [8]. Demuestra que los algoritmos genéticos pueden utilizarse eficazmente para optimizar los parámetros de sistemas neuro-difusos en diagnóstico médico, logrando mejoras significativas en exactitud respecto a los sistemas configurados manualmente por expertos.

GA Tuning Fuzzy Rule-Based Classification Systems — Cardiovascular [9]. Caso de estudio del uso de algoritmos genéticos para ajustar sistemas de clasificación difusa con conjuntos difusos de valor intervalar en diagnóstico cardiovascular. Proporciona evidencia de que el ajuste automático de parámetros mediante AG mejora consistentemente el rendimiento de los sistemas difusos.

2.4. Sistema de Lógica Difusa (Motor Mamdani)

2.4.1. El Modelo de Inferencia Mamdani

Existen dos grandes familias de sistemas de inferencia difusa: **Mamdani** y **Takagi-Sugeno**. La diferencia principal está en la forma de la salida:

- **Takagi-Sugeno:** La salida de cada regla es una función lineal (o constante) de las entradas. Es computacionalmente eficiente pero produce una salida numérica directa, lo que dificulta la interpretación lingüística del resultado.
- **Mamdani:** La salida de cada regla es también un conjunto difuso lingüístico. El resultado final se obtiene por defuzzificación de la unión de todos esos conjuntos. Es más intuitivo: tanto las entradas como la salida se expresan en términos comprensibles ("bajo riesgo", "alto riesgo").

Se eligió el modelo **Mamdani** [10] por su interpretabilidad: las reglas del sistema describen directamente la relación clínica entre los síntomas y el nivel de riesgo en lenguaje natural, y la salida es también una categoría lingüística (bajo/medio/alto) antes de ser convertida a un puntaje numérico.

2.4.2. Funciones de Membresía Trapezoidales

Una **función de membresía** $\mu_A(x)$ describe el grado con que un valor x pertenece al conjunto difuso A. El grado de membresía varía entre 0 (no pertenece) y 1 (pertenece completamente), con valores intermedios representando pertenencia parcial.

El sistema utiliza exclusivamente **funciones trapezoidales**, definidas por cuatro parámetros $[a, b, c, d]$:

$$\mu_{trap}(x;\, a, b, c, d) = \begin{cases} 0 & \text{si } x \leq a \\ \dfrac{x-a}{b-a} & \text{si } a < x \leq b \\ 1 & \text{si } b < x \leq c \\ \dfrac{d-x}{d-c} & \text{si } c < x \leq d \\ 0 & \text{si } x > d \end{cases} \tag{1}$$

donde:

- a = inicio del soporte (comienza a pertenecer)
- b = inicio del núcleo (pertenencia = 1)
- c = fin del núcleo (pertenencia = 1)
- d = fin del soporte (deja de pertenecer)

La función trapezoidal fue elegida porque permite representar de forma natural rangos clínicos con zonas de certeza plena (el núcleo, donde la presión es definitivamente "alta" sin ambigüedad) y zonas de transición gradual (las rampas laterales, donde el clínico puede no tener certeza absoluta).

[IMAGEN: Diagrama de una función trapezoidal con los puntos a, b, c, d etiquetados, mostrando el soporte, el núcleo y las rampas laterales. Eje X = valor de la variable, Eje Y = grado de membresía (0 a 1).]

Figura 2: Función de membresía trapezoidal: parámetros $[a, b, c, d]$

Fuente: Elaboración propia.

2.4.3. Variables de Entrada: Categorías y Parámetros

El siguiente cuadro resume los universos de discurso y umbrales clínicos clave que sirvieron como punto de partida para definir las funciones de membresía de cada variable.

Cuadro 1: Universos de las variables difusas: rango del dataset y referencia clínica

Variable	**Universo adoptado**	**Rango en dataset**	**Umbral clínico clave**
Edad	[10, 70] años	[10, 70]	Riesgo adolescente <20 a; AMA ≥35 a [14, 12]
Presión sistólica	[70, 160] mmHg	[70, 160]	HTA gestacional: ≥140 mmHg [12, 11]
Presión diastólica	[49, 100] mmHg	[49, 100]	HTA gestacional: ≥90 mmHg [12, 11]
Azúcar en sangre	[6.0, 19.0] mmol/L	[6.0, 19.0]	DMG: ≥8.5 mmol/L posprandial [15]
Temperatura corporal	[97, 103] °F	[97, 103]	Fiebre: ≥100.4 °F (38 °C) [17]
Frecuencia cardíaca	[60, 90] lpm	[60, 90]	Taquicardia: >100 lpm [19]

Fuente: Elaboración propia con base en las referencias clínicas indicadas.

Cada variable de entrada cuenta con 2 o 3 categorías lingüísticas. Los puntos de cada trapezoide fueron inicialmente definidos con base en los umbrales clínicos de la literatura y posteriormente refinados por el algoritmo genético.

Cuadro 2: Funciones de membresía — Edad [10, 70] años

Categoría	a	b	c	d
joven	10	10	20	28
adulta	24	28	34	38
avanzada	34	40	70	70

Fuente: Elaboración propia.

Variable 1: Edad (años) Justificación: El rango del dataset [10, 70] años [4] cubre el espectro completo de edad reproductiva documentado. La Organización Mundial de la Salud define el embarazo adolescente (menores de 20 años) como situación de alto riesgo obstétrico por inmadurez biológica del canal del parto, mayor prevalencia de desnutrición materna y acceso limitado a atención prenatal [14]. En el extremo opuesto, la "edad materna avanzada" (AMA), definida convencionalmente como ≥ 35 años por el ACOG, se asocia de forma independiente con mayor riesgo de hipertensión gestacional, diabetes gestacional, parto prematuro y anomalías cromosómicas [12]. Estudios epidemiológicos de gran escala confirman que la morbilidad materna perinatal es mínima entre los 20 y 34 años, ventana que abarca la categoría "adulta" del sistema [22, 21]. Los puntos del trapezoide "avanzada" comienzan en 34 años para capturar el riesgo creciente en los años previos al umbral oficial de AMA, cuya relevancia clínica está bien documentada [12].

Cuadro 3: Funciones de membresía — Presión Sistólica [70, 160] mmHg

Categoría	a	b	c	d
normal	70	70	110	125
elevada	120	128	138	145
alta	140	148	160	160

Fuente: Elaboración propia.

Variable 2: Presión Sistólica (mmHg) Justificación: La guía ACC/AHA 2017 clasifica la presión sistólica en: normal (<120 mmHg), elevada (120–129 mmHg), estadio 1 (130–139 mmHg) y estadio 2 (≥140 mmHg) [11]. En obstetricia, el ACOG y la OMS establecen ≥140 mmHg como umbral diagnóstico de hipertensión gestacional y criterio de sospecha de preeclampsia [12, 13]; a partir de ≥160 mmHg se considera hipertensión gestacional grave que exige tratamiento farmacológico inmediato [12]. La categoría "alta" del sistema arranca en 140 mmHg (plena certeza desde 148 mmHg) para replicar estos umbrales; la "elevada" (120–145 mmHg) cubre el estadio 1 de la AHA, zona de vigilancia intensificada; y la "normal" con núcleo hasta 110 mmHg refleja que por debajo de ese valor la presión sistólica aislada no constituye factor de riesgo gestacional [11].

Cuadro 4: Funciones de membresía — Presión Diastólica [49, 100] mmHg

Categoría	a	b	c	d
normal	49	49	70	80
elevada	76	82	90	95
alta	90	95	100	100

Fuente: Elaboración propia.

Variable 3: Presión Diastólica (mmHg) Justificación: La guía ACC/AHA 2017 clasifica la presión diastólica en: normal (<80 mmHg), estadio 1 (80–89 mmHg) y estadio 2 (≥90 mmHg) [11]. El ACOG y la OMS definen hipertensión gestacional cuando la diastólica alcanza ≥90 mmHg en dos lecturas separadas [12, 13]; este umbral fija el límite inferior de la categoría "alta" del sistema. La categoría "elevada" (76–95 mmHg) cubre el estadio 1 de la AHA y la zona de prehipertensión gestacional donde las guías recomiendan vigilancia intensificada [11]. El límite inferior del universo (49 mmHg) reproduce el mínimo del dataset [4], consistente con la vasodilatación fisiológica del segundo trimestre que puede reducir transitoriamente la presión diastólica [19].

Cuadro 5: Funciones de membresía — Azúcar en Sangre [6, 19] mmol/L

Categoría	a	b	c	d
normal	6.0	6.0	7.5	8.5
elevada	8.0	9.0	12.0	14.0
alta	12.0	14.0	19.0	19.0

Fuente: Elaboración propia.

Variable 4: Azúcar en Sangre (mmol/L) Justificación: Los valores del dataset [6.0–19.0] mmol/L corresponden a mediciones de glucemia aleatoria (no en ayunas) [4]. El grupo IADPSG establece como

criterios diagnósticos de diabetes mellitus gestacional (DMG): glucemia en ayunas ≥5.1 mmol/L, a la hora ≥10.0 mmol/L y a las dos horas ≥8.5 mmol/L en la prueba de tolerancia oral a la glucosa [15]. La Asociación Americana de Diabetes (ADA) define glucemia aleatoria ≥11.1 mmol/L (200 mg/dL) como criterio diagnóstico de diabetes en presencia de síntomas, y glucemia en ayunas ≥7.0 mmol/L como umbral de confirmación [16]. Con base en estos criterios: la categoría "normal" [6.0–8.5] mmol/L abarca el rango por debajo del umbral postprandial IADPSG; la "elevada" [8.0–14.0] mmol/L cubre desde la zona de riesgo de DMG hasta hiperglucemia notable; y la "alta" [≥12 mmol/L, certeza plena desde 14 mmol/L] representa hiperglucemia severa (>200 mg/dL) asociada con riesgo de cetoacidosis diabética y complicaciones perinatales graves [16].

Cuadro 6: Funciones de membresía — Temperatura Corporal [97, 103] °F

Categoría	a	b	c	d
normal	97.0	97.0	98.5	99.5
elevada	99.0	100.0	101.0	101.5
fiebre	101.0	101.5	103.0	103.0

Fuente: Elaboración propia.

Variable 5: Temperatura Corporal (°F) Justificación: Un estudio de referencia clásico de Mackowiak et al. estableció que la temperatura corporal normal en adultos oscila entre 36.1 y 37.2 °C (97.0–99.0 °F), con media de 36.8 °C [17]. El umbral de fiebre clínica universalmente aceptado es ≥38.0 °C (≥100.4 °F) [17]. En obstetricia, la fiebre es un signo de alarma de primer orden: puede indicar corioamnionitis, infección del tracto urinario ascendente o sepsis puerperal, condiciones asociadas con mortalidad materna y neonatal elevada [18]. La categoría "fiebre" del sistema parte desde 101 °F con soporte desde 100.4 °F, garantizando que ningún caso febril quede sin clasificar. La categoría "elevada" (99.0–101.5 °F) corresponde al rango subfebril (37.2–38.6 °C), zona de alerta incipiente con vigilancia estrecha recomendada en gestantes. El universo [97, 103] °F reproduce exactamente el rango del dataset [4].

Cuadro 7: Funciones de membresía — Frecuencia Cardíaca [60, 90] lpm

Categoría	a	b	c	d
normal	60	60	72	80
elevada	76	82	90	90

Fuente: Elaboración propia.

Variable 6: Frecuencia Cardíaca (lpm) Justificación: La frecuencia cardíaca en reposo normal para adultos es de 60–100 lpm [19]. Durante el embarazo se produce un incremento fisiológico de 10–20 lpm respecto al valor basal, con valores medios de 80–90 lpm en el tercer trimestre [19, 20]. El dataset presenta valores exclusivamente en el rango [60–90] lpm [4], lo que refleja mediciones tomadas en condiciones de reposo relativo y la ausencia de casos de taquicardia franca (>100 lpm) en la población estudiada. Por ello el universo se acota al rango observado sin extrapolación. La categoría "normal" [60–80] lpm abarca los valores de reposo habituales en el embarazo; la "elevada" [76–90] lpm corresponde a frecuencia alta pero fisiológicamente posible en gestantes (asociada con anemia, deshidratación o estrés)

sin llegar a taquicardia patológica [20]. Esta variable tiene menor poder discriminativo en el dataset, lo que justifica sus solo dos categorías y la ausencia de reglas de alto riesgo autónomas para ella.

[IMAGEN: Gráfica con 6 subplots (uno por variable) mostrando las funciones de membresía trapezoidales de cada categoría. Por ejemplo, para edad: tres curvas solapadas (joven/adulta/avanzada) sobre el eje X de 10 a 70.]

Figura 3: Funciones de membresía de las seis variables de entrada

Fuente: Elaboración propia.

2.4.4. Variable de Salida: Puntaje de Riesgo

La salida del sistema difuso es la variable **puntaje_riesgo** con universo $[0, 100]$ y tres conjuntos difusos:

Cuadro 8: Funciones de membresía — Puntaje de Riesgo [0, 100]

Categoría	a	b	c	d
bajo	0	0	25	42
medio	35	45	58	70
alto	62	75	100	100

Fuente: Elaboración propia.

El puntaje numérico resultante de la defuzzificación se convierte a etiqueta clínica mediante los siguientes umbrales:

$$\text{RiskLevel} = \begin{cases} \text{low risk} & \text{si puntaje} < 40 \\ \text{mid risk} & \text{si } 40 \leq \text{puntaje} < 65 \\ \text{high risk} & \text{si puntaje} \geq 65 \end{cases} \tag{2}$$

2.4.5. Método de Inducción de Reglas: PRISM y RIPPER

La construcción del conjunto de reglas no fue exclusivamente manual: se siguió una metodología en dos etapas fundamentada en algoritmos de inducción de reglas simbólicas, partiendo del algoritmo **PRISM** propuesto por Cendrowska [23].

Principio del Algoritmo PRISM PRISM (*Programmed Rule Induction Systematically in Modules*) es un algoritmo de aprendizaje automático que genera reglas SI...ENTONCES trabajando clase por clase [23]. Para cada clase objetivo C: (1) calcula $P(\text{clase} = C \mid \text{atributo} = \text{valor})$ para cada par atributo-valor; (2) selecciona el par de mayor probabilidad y lo añade como antecedente; (3) restringe el subconjunto a los ejemplos que satisfacen los antecedentes acumulados y repite hasta cubrir sólo instancias de C; (4) elimina los ejemplos cubiertos y reinicia hasta cubrir toda la clase. A diferencia de los árboles de decisión (estructuras jerárquicas globales), PRISM genera reglas **modulares**, donde cada regla tiene justificación independiente, propiedad esencial en sistemas médicos interpretables [23].

Primera Etapa: Aplicación Manual de PRISM En una primera fase se aplicó la lógica de PRISM de forma manual sobre el dataset discretizado, usando los umbrales clínicos como puntos de corte. Se obtuvieron conjuntos de 25–30 reglas, la mayoría con tres o cuatro antecedentes. Al evaluar el sistema difuso con estas reglas sobre el conjunto de validación, el MacroF1 fue **inferior a 0.50**, umbral inaceptable para un sistema de apoyo clínico. Las reglas eran demasiado específicas: la coincidencia simultánea de tres o cuatro condiciones ocurría en muy pocos casos reales, dejando muchas instancias sin consecuente activado con fuerza suficiente.

Segunda Etapa: Inducción Asistida con RIPPER En la segunda fase se empleó la biblioteca Python `wittgenstein`, que implementa el algoritmo **RIPPER** (*Repeated Incremental Pruning to Produce Error Reduction*) de Cohen [24]. RIPPER extiende PRISM con una fase de **poda** que elimina condiciones redundantes y reduce el sobreajuste: (1) *Fase de crecimiento:* igual que PRISM, construye una regla añadiendo condiciones que maximizan la cobertura. (2) *Fase de poda:* evalúa qué condiciones pueden eliminarse sin degradar el error en un conjunto de validación interno, produciendo reglas más cortas y generalizables. (3) *Iteración:* repite construcción-poda hasta que no se obtengan mejoras. La aplicación de RIPPER produjo reglas con mayor cobertura y menor especificidad, que fueron revisadas clínicamente para verificar coherencia médica y depuradas para eliminar las sin justificación independiente. El resultado son las **15 reglas** finales.

2.4.6. Las 15 Reglas Difusas

Cuadro 9: Reglas del sistema difuso Mamdani

Nº	Antecedentes		Justificación clínica	Consecuente
1	AS=normal PS=normal PD=normal	AND AND	Todos los indicadores primarios normales	bajo
2	AS=normal PD=normal TC=normal	AND AND	Azúcar, presión diastólica y temperatura normales	bajo

Continúa...

Nº	Antecedentes		Justificación clínica	Consecuente
3	AS=elevada PD=normal	AND	Glucemia ligeramente elevada sin hipertensión	medio
4	PS=elevada AS=normal	AND	Presión sistólica alta sin problema de glucemia	medio
5	PD=elevada AS=normal	AND	Presión diastólica alta sin problema de glucemia	medio
6	Edad=avanzada AS=normal PD=normal	AND AND	Edad $\geq$ 35 años con parámetros normales	medio
7	TC=elevada		Temperatura subfebril: posible infección incipiente	medio
8	AS=alta		Glucemia muy alta: indicador primario de alto riesgo	alto
9	AS=elevada PD=elevada	AND	Coexistencia de glucemia elevada e hipertensión	alto
10	AS=elevada PS=elevada	AND	Azúcar elevada con presión sistólica elevada	alto
11	AS=elevada Edad=avanzada	AND	Glucemia elevada en paciente de edad avanzada	alto
12	PD=alta		Presión diastólica muy alta: riesgo autonómo	alto
13	PS=alta		Presión sistólica muy alta: riesgo autonómo	alto
14	TC=fiebre		Fiebre: riesgo de infección/sepsis	alto
15	Edad=avanzada PD=elevada	AND	Edad avanzada con presión diastólica elevada	alto

Fuente: Elaboración propia.

Nomenclatura: AS = azúcar en sangre, PS = presión sistólica, PD = presión diastólica, TC = temperatura corporal.

2.4.7. Proceso de Inferencia Mamdani: Paso a Paso

El motor de inferencia implementado en `motor.py` ejecuta los siguientes pasos para cada caso:

Paso 1: Fuzzificación Dado un valor crítico x_i para la variable i, se calcula el grado de membresía de ese valor en cada uno de sus conjuntos difusos mediante la ecuación (1). Por ejemplo, para una paciente con edad = 32 años:

$$\mu_{joven}(32) = 0.0, \quad \mu_{adulta}(32) = 0.75, \quad \mu_{avanzada}(32) = 0.0 \tag{3}$$

Paso 2: Evaluación de Reglas Para cada regla k con antecedentes $(var_1, cat_1), (var_2, cat_2), \ldots$, la **fuerza de activación** se calcula como el mínimo de los grados de membresía de sus antecedentes

(operador AND difuso):

$$\alpha_k = \text{mín}\big(\mu_{cat_1}(x_{var_1}),\ \mu_{cat_2}(x_{var_2}),\ \ldots\big) \tag{4}$$

Cuando múltiples reglas apuntan al mismo consecuente, se aplica el operador OR difuso (máximo):

$$A_{consecuente} = \max_{\{k\,:\,consecuente_k = consecuente\}} \alpha_k \tag{5}$$

Paso 3: Defuzzificación por Centroide Cada conjunto difuso de salida (bajo, medio, alto) es **recortado** al nivel de activación correspondiente (método *clipping*):

$$\mu_{recortado,j}(y) = \text{mín}\big(A_j,\ \mu_{salida,j}(y)\big) \tag{6}$$

Los tres conjuntos recortados se **agregan** tomando el máximo punto a punto:

$$\mu_{agregado}(y) = \text{máx}\big(\mu_{recortado,bajo}(y),\ \mu_{recortado,medio}(y),\ \mu_{recortado,alto}(y)\big) \tag{7}$$

Finalmente, el **centroide** (centro de gravedad) del área agregada proporciona el puntaje numérico de salida:

$$y^* = \frac{\int_0^{100} y \cdot \mu_{agregado}(y)\, dy}{\int_0^{100} \mu_{agregado}(y)\, dy} \tag{8}$$

Se eligió el método del centroide sobre otras alternativas (bisección, MOM — Mean Of Maximum) porque es el más utilizado en la práctica, produce resultados suaves y continuos ante pequeñas variaciones en la entrada, y tiene una interpretación geométrica intuitiva como el "centro de peso" de la distribución difusa resultante.

Si todos los conjuntos de salida tienen activación cero (ningúna regla se dispara), el sistema retorna un puntaje neutro de 50.0 como valor de respaldo.

[IMAGEN: Diagrama del proceso Mamdani completo para un caso ejemplo. Mostrar: (1) fuzzificación de cada variable, (2) activación de reglas representativas, (3) conjuntos de salida recortados, (4) unión agregada, (5) centroide marcado con flecha.]

Figura 4: Proceso de inferencia Mamdani: fuzzificación, evaluación, agregación y defuzzificación

Fuente: Elaboración propia.

2.4.8. Implementación: Motor Vectorizado

El motor fue implementado con **procesamiento vectorizado** usando NumPy para permitir la evaluación eficiente de lotes completos de pacientes, lo cual es crítico durante la fase de optimización genética donde el sistema es evaluado miles de veces.

```python
def inferir_lote(self, entradas):
    """Clasifica un lote de casos de forma vectorizada."""
    n = len(next(iter(entradas.values())))

    # Paso 1: fuzzificar todas las variables
    pertenencias = {}
    for variable in VARIABLES_ENTRADA:
        pertenencias[variable] = {}
        universo = self.universos_entrada[variable]
        valores = np.asarray(entradas[variable], dtype=float)
        for categoria, curva in self.curvas_entrada[variable].items():
            pertenencias[variable][categoria] = np.array(
                [fuzz.interp_membership(universo, curva, v) for v in valores]
            )

    # Paso 2: evaluar reglas (AND=minimo, OR=maximo)
    act_bajo = np.zeros(n)
    act_medio = np.zeros(n)
    act_alto = np.zeros(n)
    for regla_var_cats, consecuente in self._reglas_compiladas:
        fuerza = np.ones(n)
        for variable, categoria in regla_var_cats:
            fuerza = np.minimum(fuerza, pertenencias[variable][categoria])
        np.maximum({"bajo": act_bajo, "medio": act_medio,
                    "alto": act_alto}[consecuente], fuerza,
                   out={"bajo": act_bajo, "medio": act_medio,
                        "alto": act_alto}[consecuente])
```

```python

    # Paso 3: defuzzificar cada caso (centroide)
    puntajes = np.array([
        self._desfusificar({"bajo": float(act_bajo[i]),
                            "medio": float(act_medio[i]),
                            "alto": float(act_alto[i])})
        for i in range(n)
    ])
    return {"puntajes": puntajes, "riesgos": [...], "activaciones": [...]}
```

Listing 1: Núcleo del motor de inferencia Mamdani (motor.py)

2.5. Algoritmo Genético

2.5.1. Motivación: Por qué Optimizar con un Algoritmo Genético

Las funciones de membresía base definidas por la literatura médica representan el mejor conocimiento previo disponible sobre los rangos clínicos de las variables. Sin embargo, el dataset específico de riesgo materno tiene distribuciones particulares que pueden requerir ajustes en esos parámetros para maximizar la precisión del clasificador.

El problema de encontrar los parámetros óptimos es un problema de optimización con las siguientes características:

- **Espacio continuo de alta dimensión:** 68 parámetros (genes).
- **Función objetivo no diferenciable:** el MacroF1 no tiene gradiente cálculable.
- **Múltiples objetivos en conflicto:** precisión global vs. sensibilidad al alto riesgo vs. interpretabilidad.
- **Restricciones de consistencia:** los parámetros deben formar trapezoides válidos y ordenados.

Los algoritmos genéticos son especialmente adecuados para estos problemas porque:

1. No requieren cálculo de gradientes.
2. Exploran el espacio de búsqueda en paralelo (población de soluciones).
3. Son robustos frente a máximos locales.
4. Permiten incorporar penalizaciones para múltiples objetivos en una única función escalar.

2.5.2. Codificación del Cromosoma

Cada **individuo** (solución candidata) en el algoritmo genético es un **cromosoma** — un vector de números reales que codifica todos los parámetros de las funciones de membresía.

La codificación es directa: los cuatro puntos $[a, b, c, d]$ de cada trapezoide se almacenan consecutivamente en el vector. Las variables se procesan en el siguiente orden: edad, presión sistólica, presión diastólica, azúcar en sangre, temperatura corporal, frecuencia cardíaca.

Cuadro 10: Estructura del cromosoma (68 genes)

Variable	**Categoría**	**Genes**	a	b	c & d
edad	joven	1–4	g1	g2	g3, g4
edad	adulta	5–8	g5	g6	g7, g8
edad	avanzada	9–12	g9	g10	g11, g12
pres. sist.	normal	13–16		...	
pres. sist.	elevada	17–20		...	
pres. sist.	alta	21–24		...	
pres. diast.	normal	25–28		...	
pres. diast.	elevada	29–32		...	
pres. diast.	alta	33–36		...	
azúcar s.	normal	37–40		...	
azúcar s.	elevada	41–44		...	
azúcar s.	alta	45–48		...	
temperatura	normal	49–52		...	
temperatura	elevada	53–56		...	
temperatura	fiebre	57–60		...	
frec. card.	normal	61–64		...	
frec. card.	elevada	65–68	g65, g66, g67, g68		

Fuente: Elaboración propia.

2.5.3. Población Inicial

La población inicial de 50 individuos se genera mediante una estrategia mixta:

- **65 % perturbados (32 individuos):** Variaciones del cromosoma base (parámetros definidos por literatura) con ruido gaussiano $\mathcal{N}(0, \sigma = 5\,\%$ del rango de cada gen). Esto asegura que la población inicial explore el vecindario del diseño experto.
- **35 % aleatorios (17 individuos):** Cromosomas generados uniformemente dentro de los límites válidos de cada gen. Aporta diversidad global y evita que el algoritmo quede atrapado en el vecindario del experto si existe una región mejor.
- **1 individuo exacto:** El cromosoma base sin perturbación, garantizando que el algoritmo nunca sea peor que el diseño experto inicial.

2.5.4. Función de Fitness

La función de fitness define el criterio de evaluación de cada individuo. Se diseñó como una función **multiobjetivo ponderada**:

$$\text{fitness} = 0.75 \cdot F_1^{macro} + 0.25 \cdot \text{Recall}_{alto} - 0.80 \cdot P_{interp} - 0.05 \cdot P_{desv} \tag{9}$$

A continuación se justifica cada término:

MacroF1 (peso 0.75) Para cada clase c, se definen primero **Precisión** y **Recall** a partir de la matriz de confusión:

$$\text{Precision}_c = \frac{TP_c}{TP_c + FP_c}, \qquad \text{Recall}_c = \frac{TP_c}{TP_c + FN_c} \tag{10}$$

donde TP_c son los verdaderos positivos (casos de clase c correctamente clasificados), FP_c los falsos positivos (otras clases predichas como c) y FN_c los falsos negativos (casos de clase c predichos como otra). El **F1-Score por clase** es la media armónica de ambas métricas, que penaliza severamente cuando cualquiera de las dos es baja:

$$F_1^{(c)} = \frac{2 \cdot \text{Precision}_c \cdot \text{Recall}_c}{\text{Precision}_c + \text{Recall}_c} = \frac{2\,TP_c}{2\,TP_c + FP_c + FN_c} \tag{11}$$

El **F1-Score Macro** promedia el F1 de las tres clases con igual peso:

$$F_1^{macro} = \frac{1}{3} \sum_{c \in \{\text{bajo, medio, alto}\}} F_1^{(c)} \tag{12}$$

Se eligió el promedio **macro** (en lugar de ponderado o micro) porque las tres clases reciben igual importancia sin importar su frecuencia. Con promedio ponderado, las mejoras en la clase mayoritaria dominarían la métrica; con macro, el sistema **debe clasificar bien las tres clases simultáneamente**. Se usa MacroF1 en lugar de *accuracy* porque en el dataset desbalanceado (40 % bajo, 33 % medio, 27 % alto) un clasificador que prediga siempre "bajo riesgo" obtendría 40 % de exactitud, pero $F_1^{(c)} = 0$ para las clases medio y alto, resultando en $F_1^{macro} \approx 0.13$. Esto lo convierte en la métrica más exigente e informativa, por lo que recibe el peso dominante de 0.75 en la función de fitness.

Recall de Alto Riesgo (peso 0.25)

$$\text{Recall}_{alto} = \frac{TP_{alto}}{TP_{alto} + FN_{alto}} \tag{13}$$

El recall mide qué proporción de los casos de alto riesgo reales son correctamente identificados. En el contexto médico, un falso negativo en alto riesgo (clasificar como bajo o medio a una paciente realmente en peligro) tiene consecuencias potencialmente letales. Por ello se incluye explícitamente como término de optimización con un peso adicional de 0.25, complementando al MacroF1 con un énfasis extra en no perder casos críticos.

Penalización de Interpretabilidad (peso 0.80)

$$P_{interp} = \frac{1}{2}\left(P_{huecos} + P_{solapamiento}\right) \tag{14}$$

Un cromosoma puede ser muy preciso pero producir funciones de membresía que no tienen sentido clínico (por ejemplo, con grandes huecos entre categorías contiguas o con solapamientos excesivos que impidan distinguirlas). La penalización de interpretabilidad mide y penaliza estos dos defectos:

- P_{huecos}: penaliza intervalos vacíos entre dos categorías vecinas (un valor en ese intervalo no pertenecería a ninguna categoría).
- $P_{solapamiento}$: penaliza solapamientos mayores al 30 % del soporte del trapezoide más pequeño (las categorías se confundirían entre sí).

El peso alto (0.80) refleja que la interpretabilidad del sistema es una prioridad del diseño —es precisamente lo que diferencia a este sistema de una caja negra.

Penalización de Desviación (peso 0.05)

$$P_{desv} = \frac{1}{68} \sum_{i=1}^{68} \frac{|g_i - g_i^{base}|}{rango_i} \tag{15}$$

Penaliza soluciones que se alejan mucho del diseño experto original, medido gen a gen como fracción del rango de cada variable. Esto actúa como un regularizador que *ancla* la búsqueda alrededor del conocimiento clínico previo. El peso pequeño (0.05) permite al AG alejarse del experto si la mejora en precisión lo justifica, pero lo desincentiva sin razón.

2.5.5. Selección por Torneo

Se utilizó **selección por torneo** con tamaño $k = 3$. En cada torneo, se eligen aleatoriamente 3 individuos de la población y el de mayor fitness pasa a ser padre. Este proceso se repite hasta seleccionar todos los padres necesarios.

Ventajas sobre alternativas:

- *Ruleta (fitness proporcional):* Funciona mal cuando hay grandes diferencias de fitness entre individuos (el mejor domina casi toda la selección, reduciendo diversidad). El torneo es más robusto.
- *Selección por rango:* Más justa que la ruleta pero ignora la magnitud de las diferencias. El torneo con $k = 3$ ofrece un buen balance entre presión selectiva y mantenimiento de diversidad.

2.5.6. Cruce Aritmético

Se implementó **cruce aritmético** con probabilidad de cruce $p_c = 0.85$. Dados dos padres P_1 y P_2, los hijos H_1 y H_2 se generan como:

$$H_1 = \lambda \cdot P_1 + (1 - \lambda) \cdot P_2, \qquad H_2 = (1 - \lambda) \cdot P_1 + \lambda \cdot P_2 \tag{16}$$

donde λ se genera aleatoriamente por gen desde una distribución uniforme $\mathcal{U}(0.25,\, 0.75)$.

Por qué cruce aritmético y no cruce de un punto:

- El cruce de un punto divide el cromosoma en dos segmentos y los intercambia. Para cromosomas donde los genes representan parámetros continuos relacionados (puntos de un trapezoide), este intercambio puede producir hijos geométricamente inconsistentes.
- El cruce aritmético genera hijos como combinaciones lineales de los padres, produciendo siempre valores intermedios que tienen una interpretación geométrica natural (promedio ponderado de las funciones de membresía de los padres).
- Restringir $\lambda \in [0.25, 0.75]$ evita producir hijos idénticos a uno de los padres ($\lambda = 0$ o $\lambda = 1$) y garantiza que cada hijo combine información de ambos.

2.5.7. Mutación Gaussiana

Cada gen g_i de cada individuo muta con probabilidad $p_m = 0.04$ (4 %). Cuando muta, se le suma ruido gaussiano:

$$g_i' = g_i + \mathcal{N}(0,\ \sigma_i), \qquad \sigma_i = 0.05 \cdot rango_i \tag{17}$$

Por qué mutación gaussiana y no uniforme:

- La mutación uniforme reemplaza el gen por un valor aleatorio en todo su rango. Esto introduce cambios muy abruptos que destruyen la información acumulada durante la evolución.
- La mutación gaussiana produce pequeñas perturbaciones alrededor del valor actual, explorando el vecindario local del individuo. Es más apropiada para espacios continuos donde soluciones próximas tienen fitness similar (paisaje de fitness suave).
- $\sigma = 5\,\%$ del rango de cada gen es suficiente para escapar mínimos locales sin destruir las soluciones buenas.

2.5.8. Elitismo

Se preservan los **3 mejores individuos** de cada generación (elitismo = 3) que pasan directamente a la siguiente generación sin modificación. Esto garantiza que el fitness del mejor individuo **nunca decrece** a lo largo de las generaciones, previniendo la pérdida de buenas soluciones por efectos aleatorios del cruce y la mutación.

2.5.9. Early Stopping

El algoritmo se detiene anticipadamente si transcurren **20 generaciones consecutivas** sin mejora en el fitness del mejor individuo (paciencia = 20).

Esta estrategia evita el sobreentrenamiento (el AG sigue explorando mucho tiempo después de haber convergido, sin ganancia real) y reduce el tiempo de cómputo cuando la población ha convergido.

2.5.10. Mecanismo de Reparación del Cromosoma

Después del cruce y la mutación, un cromosoma puede volverse **inválido**: trapezoides con puntos desordenados ($a > b$), rangos fuera de los límites de la variable, o categorías con solapamiento excesivo. La función `reparar_cromosoma` aplica las siguientes correcciones en 5 iteraciones:

1. **Recorte al dominio:** $g_i = \text{clip}(g_i,\ \text{lím}_{inf},\ \text{lím}_{sup})$
2. **Ordenamiento de puntos:** garantiza $a \leq b \leq c \leq d$
3. **Ancho mínimo:** si el soporte $d - a$ es menor que $\epsilon/2$, se abre desde el centro
4. **Eliminación de huecos:** si dos trapecios vecinos no se tocan ($d_{izq} < a_{der}$), se unen en su punto medio

5. **Reducción de solapamiento:** si el solapamiento supera el 30 % del soporte del menor, se reduce simétricamente

6. **Separación de núcleos:** si el núcleo de un trapezoide invade el de su vecino, se separan $\pm\epsilon/2$

La reparación se aplica después de la inicialización, después del cruce y después de la mutación. Esto garantiza que **todos los individuos evaluados siempre representen sistemas difusos válidos e interpretables**.

```python
def evaluar_individuo(cromosoma, datos_validacion):
    cromosoma_reparado = reparar_cromosoma(cromosoma)
    sistema = SistemaDifusoMamdani(decodificar_cromosoma(cromosoma_reparado))
    inferencia = sistema.inferir_lote(datos_validacion["entradas"])

    macro_f1   = calcular_macro_f1(datos_validacion["riesgos"],
                                   inferencia["riesgos"])
    recall_alto = calcular_recall_de_riesgo_alto(datos_validacion["riesgos"],
                                                 inferencia["riesgos"])
    p_interp  = calcular_penalizacion_interpretabilidad(cromosoma_reparado)
    p_desv    = calcular_penalizacion_desviacion(cromosoma_reparado,
                                                 CROMOSOMA_BASE, RANGOS_GENES)

    fitness = (0.75 * macro_f1
             + 0.25 * recall_alto
             - 0.80 * p_interp["total"]
             - 0.05 * p_desv)
    return fitness
```

Listing 2: Función de fitness (algoritmo_genetico.py)

2.5.11. Parámetros del Algoritmo Genético

Cuadro 11: Hiperparámetros del algoritmo genético

Parámetro	Descripción	Valor
Tamaño de población	Individuos por generación	50
Máx. generaciones	Límite superior de iteraciones	60
Paciencia (early stopping)	Generaciones sin mejora para detener	20
Probabilidad de cruce	p_c	0.85
Probabilidad de mutación	p_m por gen	0.04
Tamaño de torneo	k	3
Elitismo	Mejores individuos preservados	3
λ mín. cruce	Límite inferior del coeficiente de mezcla	0.25
λ máx. cruce	Límite superior del coeficiente de mezcla	0.75
σ mutación	Intensidad relativa al rango de cada gen	5 %
Fracción perturbada	Porción de pob. inicial cercana al experto	65 %
Fracción aleatoria	Porción de pob. inicial completamente aleatoria	35 %
Tamaño del cromosoma	Número de genes	68

Fuente: Elaboración propia.

2.6. Arquitectura del Sistema

2.6.1. Visión General

El sistema se compone de dos aplicaciones independientes que se comunican vía HTTP:

- **Backend:** API REST implementada en Python con FastAPI. Contiene toda la lógica de inferencia difusa, el motor de optimización genética y la gestión del modelo persistido.
- **Frontend:** Aplicación web implementada en React con TypeScript, Vite y Tailwind CSS. Provee la interfaz de usuario para ingresar datos de pacientes, visualizar el nivel de riesgo y explorar las curvas de membresía.

2.6.2. Flujo Completo de una Predicción

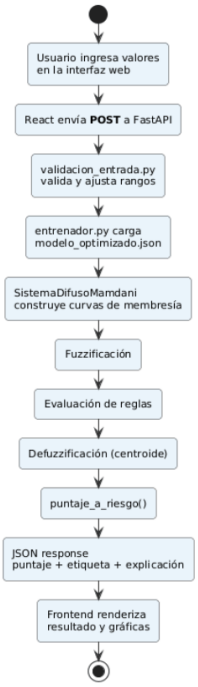

Figura 5: Flujo completo de predicción en el sistema

Fuente: Elaboración propia.

2.6.3. Estructura del Proyecto

```
proyecto_ia_1/
|-- backend/
|   \-- src/
|       |-- app/                    # FastAPI: rutas y controladores
|       |   |-- main.py             # Configuracion CORS, routers
|       |   \-- controllers/        # Endpoints HTTP
|       \-- riesgo_materno/         # Paquete central
```

```
|           |-- datos/              # CSV del dataset
|           |-- modelos/            # modelo_optimizado.json
|           |-- logica_difusa/      # motor.py, variables.py, reglas.py
|           |-- optimizacion/       # algoritmo_genetico.py, cromosoma.py
|           |-- entrenamiento/      # entrenador.py, evaluacion.py
|           \-- prediccion/         # predictor.py, validacion_entrada.py
\-- frontend/
    \-- src/
        |-- components/             # Componentes React reutilizables
        \-- pages/                  # Vistas principales
```

2.6.4. Persistencia del Modelo

El resultado del proceso de optimización genética se almacena en `modelo_optimizado.json`, que contiene:

- El cromosoma optimizado (68 valores flotantes) que define las funciones de membresía finales.
- El historial de entrenamiento por generación: fitness, MacroF1 y recall en validación.
- Las métricas de evaluación final en los tres subconjuntos (entrenamiento, validación, prueba).

En tiempo de predicción, el sistema carga este archivo y reconstruye el sistema difuso completo en memoria, sin necesidad de re-ejecutar el proceso de optimización.

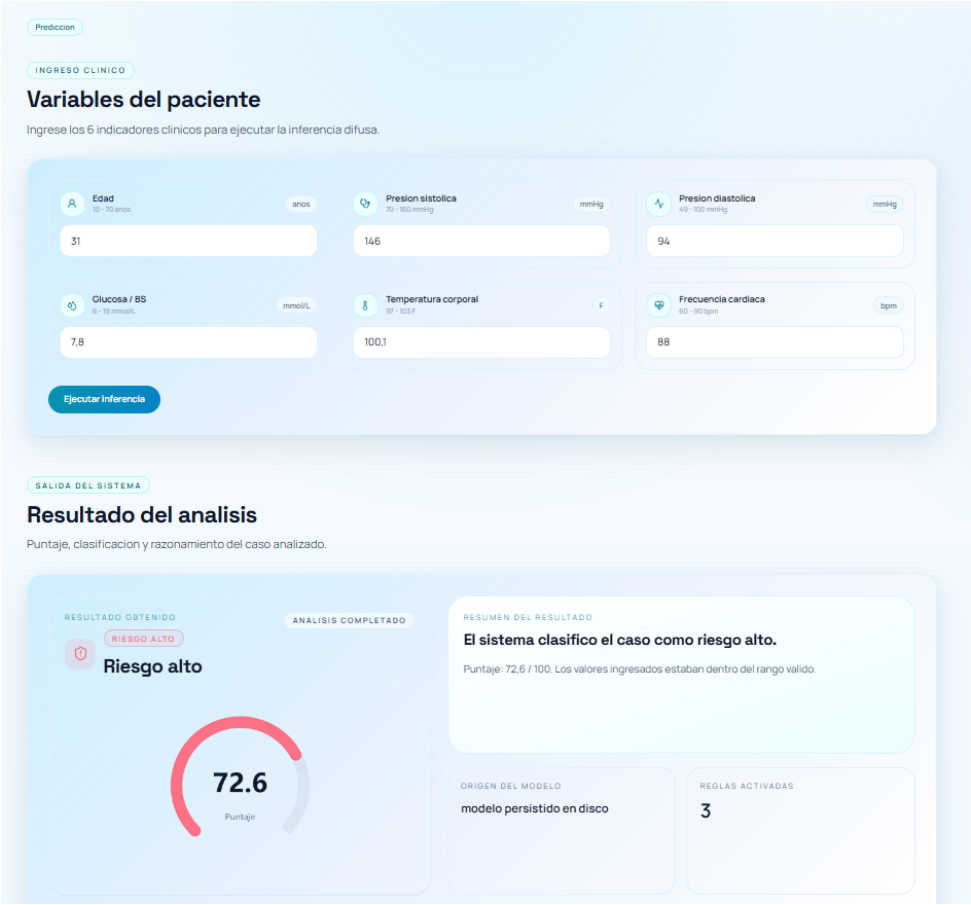

Figura 6: Interfaz web del sistema de predicción de riesgo materno

Fuente: Elaboración propia.

2.7. Resultados y Análisis

2.7.1. Comparativa Base vs. Optimizado

La siguiente tabla compara el rendimiento del sistema difuso con los parámetros base (definidos por literatura) frente al sistema optimizado (parámetros ajustados por el algoritmo genético tras 60 generaciones):

Cuadro 12: Comparativa de métricas: sistema base vs. sistema optimizado

Métrica	**Base**	**Optimizado**	**Δ**
MacroF1 — Validación	0.455	0.663	**+0.208**
MacroF1 — Prueba	0.469	0.610	**+0.141**
Recall Alto Riesgo — Validación	0.659	0.829	**+0.170**
Recall Alto Riesgo — Prueba	0.707	0.756	**+0.049**
Exactitud Balanceada — Prueba	0.485	0.611	**+0.126**

Fuente: Elaboración propia.

2.7.2. Evolución del Fitness

[IMAGEN: Gráfica de línea con el eje X = generación (0 a 60) y el eje Y = valor de fitness. Mostrar dos curvas: mejor fitness por generación y fitness promedio de la población. Marcar con punto la generación donde se alcanzó el mejor resultado (generación 52 aprox. con fitness = 0.703).]

Figura 7: Evolución del fitness a lo largo de las 60 generaciones del algoritmo genético

Fuente: Elaboración propia.

El proceso de optimización partió de un fitness inicial de 0.566 (generación 0) y alcanzó su mejor valor de 0.703 en la generación 52, moment en que el MacroF1 en validación era de 0.663. El algoritmo se estabilizó en la generación 60 por criterio de early stopping (20 generaciones sin mejora).

2.7.3. Análisis de Resultados

¿Por qué mejoró el sistema?

El AG encontró funciones de membresía que se adaptan mejor a la distribución específica del dataset de riesgo materno. En particular, los límites de las categorías de azúcar en sangre —el predictor más fuerte de alto riesgo— probablemente se ajustaron para capturar mejor el umbral entre casos de riesgo medio y alto según la distribución real de los datos.

¿Por qué la mejora en prueba es menor que en validación?

Esto es esperado: la optimización se realiza sobre el conjunto de validación, por lo que el sistema está "ajustado" a ese subconjunto. La diferencia entre validación (+20.8 % MacroF1) y prueba (+14.1 % MacroF1) indica una pequeña sobreoptimización, contenida por las penalizaciones de interpretabilidad y desviación que regularizaron la búsqueda.

Recall de alto riesgo:

El sistema optimizado identifica correctamente el 75.6 % de los casos de alto riesgo en el conjunto de prueba, frente al 70.7 % del sistema base. En el contexto médico, cada caso de alto riesgo no detectado representa un potencial fallo clínico, por lo que esta mejora es clínicamente significativa.

2.8. Análisis de Sensibilidad

2.8.1. Variable más Influyente

La estructura de las reglas (Tabla 9) revela la jerarquía de importancia de las variables:

- **Azúcar en sangre:** Es el predictor más fuerte. La regla 8 (*si AS=alta* $\Rightarrow$ *alto riesgo*) se activa de forma autónoma. Aparece en 6 de las 15 reglas.
- **Presión arterial (sistólica y diastólica):** Segunda en importancia. Cada una tiene una regla que la convierte en indicador de alto riesgo por sí sola (reglas 12 y 13).
- **Temperatura corporal:** La fiebre también activa alto riesgo de forma independiente (regla 14), por su asociación con sepsis.
- **Frecuencia cardíaca:** Variable de menor impacto. Solo tiene 2 categorías y no genera alto riesgo por sí sola.

2.8.2. Casos Extremos

Cuando azúcar en sangre = 19 mmol/L (máximo del rango), la regla 8 se activa con fuerza 1.0 y el sistema produce directamente puntaje $\geq$ 75 (alto riesgo), independientemente de los valores de las demás variables. Esto refleja el criterio clínico de que la hiperglucemia severa por sí sola es una emergencia obstétrica.

2.9. Limitaciones

1. **Tamaño del dataset:** 1.012 registros es un número modesto para el entrenamiento de un sistema clínico. Un dataset mayor permitiría un ajuste más robusto y generalizable de las funciones de membresía.
2. **Origen geográfico:** El dataset fue recolectado en zonas rurales de Bangladesh. Los rangos clínicos y la prevalencia de las condiciones de riesgo pueden diferir en otras regiones o poblaciones, limitando la generalizabilidad del sistema.
3. **Reglas basadas en literatura general:** Las 15 reglas fueron diseñadas a partir de literatura médica internacional y no fueron validadas por especialistas en obstetricia locales. Un proceso de validación con médicos expertos fortalecería la base clínica del sistema.
4. **Sin validación clínica prospectiva:** El sistema no ha sido evaluado en condiciones de uso real con pacientes reales. Su uso en entornos clínicos requeríria estudios prospectivos que comparen sus predicciones con diagnósticos médicos y resultados perinatales.
5. **Variables no incluidas:** Condiciones relevantes como historial de preeclampsia, diabetes gestacional previa, o multiparidad no están disponibles en el dataset y por tanto no son consideradas por el sistema.

2.10. Conclusiones

1. Se diseñó e implementó exitosamente un sistema de clasificación de riesgo materno basado en lógica difusa Mamdani, capaz de clasificar pacientes embarazadas en tres niveles de riesgo a partir de seis parámetros clínicos básicos, con reglas transparentes y auditables.

2. El algoritmo genético optimizó las funciones de membresía trapezoidales del sistema difuso, mejorando el MacroF1 en el conjunto de prueba en un 14.1 % (de 0.469 a 0.610) y el recall de alto riesgo en un 4.9 % (de 0.707 a 0.756) respecto al diseño base.

3. La función de fitness multiobjetivo diseñada —que pondera MacroF1, recall de alto riesgo, interpretabilidad y desviación del experto— demostró ser efectiva para equilibrar precisión clínica e interpretabilidad del sistema.

4. El mecanismo de reparación del cromosoma garantizó que todos los individuos evaluados durante la optimización fueran sistemas difusos válidos, lo que permitió al AG explorar el espacio de búsqueda sin generar soluciones inconsistentes.

5. La arquitectura implementada (FastAPI + React) provee una plataforma funcional y extensible para la consulta interactiva del sistema, con potencial de despliegue en entornos de atención primaria de salud.

2.11. Recomendaciones

1. Ampliar el dataset con registros de diversas regiones geográficas y grupos poblacionales para mejorar la generalizabilidad del sistema optimizado.

2. Involucrar a médicos obstetras en la revisión y validación de las reglas difusas, para asegurar que el conocimiento clínico codificado corresponda a la práctica médica local.

3. Explorar técnicas de optimización multiobjetivo explícita (como NSGA-II) para obtener frentes de Pareto entre precisión e interpretabilidad, en lugar de combinarlos en una única función escalar ponderada.

4. Implementar un mecanismo de reentrenamiento automático que permita actualizar las funciones de membresía cuando se incorporen nuevos datos al sistema, manteniendo su precisión a lo largo del tiempo.

5. Realizar una evaluación clínica prospectiva del sistema en condiciones reales de uso, comparando sus predicciones con el criterio médico especializado para cuantificar su utilidad práctica.

2.12. Referencias Bibliográficas

[1] World Health Organization, "Maternal Mortality," WHO Fact Sheet, 2023. [Online]. Available: `https://www.who.int/news-room/fact-sheets/detail/maternal-mortality`.

[2] L. A. Zadeh, "Fuzzy Sets," *Inf. Control*, vol. 8, no. 3, pp. 338–353, 1965.

[3] J. H. Holland, *Adaptation in Natural and Artificial Systems*. Ann Arbor, MI: University of Michigan Press, 1975.

[4] M. Ahmed et al., "Maternal Health Risk Data Set," UCI Machine Learning Repository, 2020. DOI: 10.24432/C5DP5D.

[5] M. Apriceno et al., "A Trustworthy Evolutionary Fuzzy Neural Network Framework for Maternal Health Risk Classification," in *Proc. AIME 2025*, Lecture Notes in Computer Science, vol. 15871, Springer, 2025, pp. 32–42. DOI: 10.1007/978-3-031-95841-0_4.

[6] C. S. Lima et al., "An Explainable Fuzzy Framework for Assessing Preeclampsia Classification," *Biomedicines*, vol. 13, no. 6, p. 1483, 2025. DOI: 10.3390/biomedicines13061483. PMC: PMC12190940.

[7] E. Papageorgiou, C. Salmeron, and F. Marotta, "Fuzzy Logic Intelligent Systems and Methods in Midwifery and Obstetrics," *Int. J. Environ. Res. Public Health*, vol. 18, no. 21, 2021. PMC: PMC8563028.

[8] A. R. Rashed and O. M. Al-Hazaimeh, "Enhanced Neuro-Fuzzy System Based on Genetic Algorithm for Medical Diagnosis," *J. Biosens. Bioelectron.*, vol. 7, no. 2, 2016. DOI: 10.4172/2155-6210.1000211.

[9] J. Alcalá-Fdez, R. Alcalá, and F. Herrera, "A Fuzzy Association Rule-Based Classification Model for High-Dimensional Problems with Genetic Rule Selection and Lateral Tuning," *IEEE Trans. Fuzzy Syst.*, vol. 19, no. 5, pp. 857–872, 2011.

[10] E. H. Mamdani and S. Assilian, "An Experiment in Linguistic Synthesis with a Fuzzy Logic Controller," *Int. J. Man-Mach. Stud.*, vol. 7, no. 1, pp. 1–13, 1975.

[11] P. K. Whelton et al., "2017 ACC/AHA/AAPA/ABC/ACPM/AGS/APhA/ASH/ASPC/NMA/PCNA Guideline for the Prevention, Detection, Evaluation, and Management of High Blood Pressure in Adults," *J. Am. Coll. Cardiol.*, vol. 71, no. 19, pp. e127–e248, 2018. DOI: 10.1016/j.jacc.2017.11.006.

[12] American College of Obstetricians and Gynecologists, "Gestational Hypertension and Preeclampsia: ACOG Practice Bulletin, Number 222," *Obstet. Gynecol.*, vol. 135, no. 6, pp. e237–e260, 2020. DOI: 10.1097/AOG.0000000000003891.

[13] World Health Organization, *WHO Recommendations for Prevention and Treatment of Pre-Eclampsia and Eclampsia*. Geneva: WHO Press, 2011. ISBN: 978-92-4-154833-5.

[14] World Health Organization, "Adolescent Pregnancy," WHO Fact Sheet, 2023. [Online]. Available: `https://www.who.int/news-room/fact-sheets/detail/adolescent-pregnancy`.

[15] International Association of Diabetes and Pregnancy Study Groups Consensus Panel, "Recommendations on the Diagnosis and Classification of Hyperglycemia in Pregnancy," *Diabetes Care*, vol. 33, no. 3, pp. 676–682, 2010. DOI: 10.2337/dc09-1848.

[16] American Diabetes Association Professional Practice Committee, "Standards of Medical Care in Diabetes—2024," *Diabetes Care*, vol. 47, suppl. 1, pp. S1–S321, 2024. DOI: 10.2337/dc24-SINT.

[17] P. A. Mackowiak, S. S. Wasserman, and M. M. Levine, "A Critical Appraisal of 98.6°F, the Upper Limit of the Normal Body Temperature, and Other Legacies of Carl Reinhold August Wunderlich," *JAMA*, vol. 268, no. 12, pp. 1578–1580, 1992. DOI: 10.1001/jama.1992.03490120092034.

[18] D. E. Soper, "Fever in the Obstetric Patient," *Obstet. Gynecol. Clin. North Am.*, vol. 36, no. 4, pp. 685–696, 2009. DOI: 10.1016/j.ogc.2009.10.002.

[19] M. Monga and B. M. Creasy, "Cardiovascular and Renal Adaptation to Pregnancy," in *Maternal-Fetal Medicine: Principles and Practice*, 4th ed., R. K. Creasy and R. Resnik, Eds. Philadelphia, PA: W. B. Saunders, 1994, pp. 789–799.

[20] M. Sanghavi and J. D. Rutherford, "Cardiovascular Physiology of Pregnancy," *Circulation*, vol. 130, no. 12, pp. 1003–1008, 2014. DOI: 10.1161/CIRCULATIONAHA.114.009029.

[21] Y. Yogev et al., "Maternal Age and Adverse Perinatal Outcomes in Patients with Gestational Diabetes Mellitus," *J. Matern. Fetal Neonatal Med.*, vol. 23, no. 4, pp. 255–261, 2010. DOI: 10.3109/14767050903163018.

[22] P. A. Cavazos-Rehg et al., "Maternal Age and Risk of Labor and Delivery Complications," *Matern. Child Health J.*, vol. 19, no. 6, pp. 1202–1211, 2015. DOI: 10.1007/s10995-014-1624-7.

[23] J. Cendrowska, "PRISM: An Algorithm for Inducing Modular Rules," *Int. J. Man-Mach. Stud.*, vol. 27, no. 4, pp. 349–370, 1987. DOI: 10.1016/S0020-7373(87)80003-2.

[24] W. W. Cohen, "Fast Effective Rule Induction," in *Proc. 12th Int. Conf. Mach. Learn. (ICML 1995)*, Tahoe City, CA, USA, Jul. 1995, pp. 115–123.